

Simulação de opinião pública sobre desigualdade no Brasil com um LLM aberto pequeno: comparação com Random Forest a partir da pesquisa CESOP/IPEC 04839

Bruno Ferrão¹

¹Faculdade de Computação e Informática — Universidade Presbiteriana Mackenzie

RA 10401081 — São Paulo, SP — Brasil

bruno_ferrao01@hotmail.com

Resumo.

Este trabalho testa um LLM aberto pequeno como simulador de respostas a uma pesquisa brasileira de opinião pública sobre desigualdade. Usamos o Qwen2.5-0.5B-Instruct (500 milhões de parâmetros, licença Apache 2.0) para simular 200 respondentes da pesquisa CESOP/IPEC 04839 em duas afirmações com escala Likert de cinco pontos, e comparamos os resultados com um Random Forest treinado nas mesmas variáveis sociodemográficas. O Random Forest venceu em todas as métricas: acurácia individual de 0,335 (P6A) e 0,440 (P6C) contra 0,145 e 0,130 do LLM, e divergência KL quatro a seis vezes menor. O achado mais interessante apareceu na distribuição das respostas: o LLM concentrou 51% (P6A) e 67% (P6C) das simulações em "Discorda totalmente", enquanto a

população real concentra 39% e 45% em "Concorda totalmente". Os dois modelos têm vieses fortes, mas em direções opostas: o LLM puxa para a discordância, possivelmente por alinhamento defensivo em temas sensíveis; o Random Forest puxa para a moda da amostra. A análise de importância de variáveis aponta religião e faixa etária como as mais preditivas, e sexo como a menos.

Abstract.

We test a small open LLM as a simulator for a Brazilian public opinion survey on inequality. We use Qwen2.5-0.5B-Instruct (500M parameters, Apache 2.0) to simulate 200 respondents of the CESOP/IPEC 04839 survey on two five-point Likert statements, and compare it to a Random Forest trained on the same sociodemographic variables. Random Forest won on every metric: individual accuracy of 0.335 (P6A) and 0.440 (P6C) against 0.145 and 0.130 from the LLM, and KL divergence four to six times lower. The more interesting result is the response distribution: the LLM put 51% (P6A) and 67% (P6C) of its predictions on "Strongly Disagree", while the actual population concentrates 39% and 45% on "Strongly Agree". Both models show strong biases in opposite directions: the LLM leans toward disagreement, probably reflecting defensive alignment on sensitive topics; Random Forest collapses toward the dataset mode. Variable importance shows religion and age band as the strongest predictors, and sex as the weakest.

1. Introdução

A ideia de usar LLMs para simular respondentes de pesquisas de opinião tem nome próprio na literatura: *silicon sampling*. A motivação é direta. Pesquisa de campo é cara, demorada e tem problemas conhecidos de não-resposta. Se um modelo de linguagem condicionado num perfil sociodemográfico consegue reproduzir respostas plausíveis, abre-se uma alternativa barata para estudos exploratórios ou para sondar vieses culturais dos próprios modelos. Argyle et al. (2023) mostraram que GPT-3 condicionado em perfis do American National Election Study reproduz padrões de voto agregados com fidelidade alta. Trabalhos posteriores como Bisbee et al. (2024) alertam que esse sucesso é frágil: pequenas mudanças de prompt mudam radicalmente o resultado, e modelos costumam ter vieses sistemáticos em temas politicamente sensíveis.

Quase toda essa literatura usa modelos grandes (GPT-3.5, GPT-4, Llama-3-70B) e dados de pesquisa em inglês. Este trabalho explora a outra ponta: um modelo *pequeno* (500 milhões de parâmetros), totalmente aberto, e dados de pesquisa em português brasileiro sobre desigualdade. O objetivo não é tirar conclusões sobre LLMs em geral, mas estabelecer um piso de capacidade. Se esse modelo simula bem, dá para fazer *silicon sampling* sem GPU e sem chave de API; se simula mal, vale entender exatamente como ele erra.

A pesquisa escolhida é a CESOP/IPEC 04839, *Percepção dos brasileiros sobre temas relacionados à desigualdade*, com 2.000 entrevistas presenciais feitas pelo IPEC em julho de 2023. Seleccionamos duas afirmações da Pergunta 6, ambas com escala Likert de cinco pontos: **P6A**: "A abordagem policial é baseada

no tipo de cabelo, tipo de vestimenta e cor de pele das pessoas." **P6C:** "Aumentar a representatividade de pessoas negras, mulheres e população LGBTQIA+ na política e em cargos de poder contribui para diminuir as desigualdades estruturais."

Comparamos o LLM com um Random Forest treinado nas mesmas sete variáveis sociodemográficas, e relatamos três coisas: acurácia individual, aderência distribucional via divergência KL e importância relativa das variáveis preditoras.

2. Trabalhos relacionados

O artigo de referência do projeto (Entropy 2025) compara LLMs e Random Forests em tarefas de *silicon sampling* sobre dados do General Social Survey. A conclusão é que cada um tem um nicho: o LLM é melhor em reproduzir distribuições agregadas mesmo com poucos atributos, e o Random Forest é melhor em predição individual quando há volume razoável de dados rotulados. Esse achado nos serviu de hipótese a verificar.

Argyle et al. (2023), que cunharam o termo *silicon sampling*, mostraram que LLMs grandes conseguem reproduzir padrões eleitorais americanos com correlação acima de 0,8 entre votos simulados e reais por subgrupo demográfico. Bisbee et al. (2024) reanalisaram esses dados e encontraram que a fidelidade cai sensivelmente com mudanças mínimas de *prompt*, e que existem vieses sistemáticos em temas como aborto e armas.

Para o português brasileiro, o tema é pouco explorado. Não encontramos estudos publicados que aplicam *silicon sampling* a pesquisas CESOP. Este trabalho é uma primeira sondagem.

3. Metodologia

3.1. Dados

Pesquisa CESOP/IPEC 04839, *Percepção dos brasileiros sobre temas relacionados à desigualdade*. Amostra original de 2.000 entrevistas pessoais em 127 municípios, população de 16 anos ou mais, coleta entre 01 e 05 de julho de 2023, margem de erro de 2 pontos percentuais com 95% de confiança.

Excluímos respondentes com dados faltantes nas variáveis selecionadas e quem respondeu "Não sabe" ou "Não respondeu" nas duas questões alvo. Restaram 1.854 respondentes. Desses, sorteamos uma amostra estratificada de 200 (cruzando sexo e região), atendendo aos 10% mínimos exigidos no enunciado do projeto.

3.2. Variáveis

Sete preditoras sociodemográficas: sexo (2 níveis), faixa etária (6), escolaridade agrupada (6), cor/raça (5),

religião (20), renda familiar (8) e região do país (5). Duas variáveis-alvo (P6A e P6C), ambas em escala Likert de cinco pontos.

3.3. LLM

Usamos o Qwen2.5-0.5B-Instruct, da Alibaba, lançado em setembro de 2024 sob licença Apache 2.0. O motivo da escolha foi prático. Precisávamos de um modelo totalmente aberto (regra do projeto), executável em CPU comum e com suporte nativo a português e *chat template*. O Qwen-0.5B atende os três critérios e cabe em menos de 1 GB em FP32, o que permite reproduzir o experimento em qualquer notebook recente sem GPU.

A escolha deliberada de um modelo pequeno traz uma vantagem analítica: estabelece um piso. Se ele falha em alguma tarefa, sabemos que é piso. Se acerta, é evidência forte de que a tarefa é tratável.

3.4. Engenharia de prompt

Cada respondente vira um *prompt* com duas partes. Uma instrução de sistema descreve o papel ("respondente brasileiro de pesquisa do IPEC/CESOP") e a tarefa ("escolha um número de 1 a 5"). Em seguida, uma mensagem de usuário lista o perfil sociodemográfico e a afirmação a ser respondida. Exemplo:

[Sistema] Você será apresentado a um perfil sociodemográfico de um respondente brasileiro de uma pesquisa de opinião pública do IPEC/Cesop sobre desigualdade no Brasil (2023). Sua tarefa é simular qual seria a resposta mais provável desse respondente a uma afirmação. Responda somente com um número entre 1 e 5: 1 = Concorda totalmente; 2 = Concorda em parte; 3 = Não concorda, nem discorda; 4 = Discorda em parte; 5 = Discorda totalmente.

[Usuário] Perfil: Feminino, 35-44 anos, Superior completo, Parda, Católica, renda familiar de 2 a 5 salários mínimos, Sudeste. Afirmação: "A abordagem policial é baseada no tipo de cabelo, tipo de vestimenta e cor de pele das pessoas." Qual a resposta mais provável? Responda apenas com o número.

Rodamos cada respondente três vezes (*temperature* = 0,8 e *top-p* = 0,9), totalizando $200 \times 2 \times 3 = 1.200$ inferências. O tempo total em CPU Intel foi de 578 segundos, ou pouco menos de 10 minutos.

3.5. Baseline supervisionado

Treinamos um Random Forest (200 árvores, profundidade máxima 8) sobre as mesmas variáveis, codificadas com *Label Encoding*. Avaliamos com validação cruzada estratificada em cinco folds. As importâncias de variável vêm de um modelo treinado em toda a amostra.

3.6. Métricas

Quatro métricas: acurácia individual (*exact match* na escala Likert), MAE (erro médio em pontos na escala), divergência KL entre a distribuição prevista e a real, e importância relativa das variáveis no Random Forest.

4. Resultados

4.1. Métricas quantitativas

A Tabela 1 resume os números. O Random Forest é superior em todas as métricas e nas duas questões. A acurácia individual fica 2,3× maior em P6A e 3,4× maior em P6C, e a divergência KL é quatro a seis vezes menor.

Questão	Modelo	Acurácia	MAE	KL
P6A	LLM Qwen2.5-0.5B	0,145	2,072	0,958
P6A	Random Forest (5-CV)	0,335 ± 0,034	1,460	0,216
P6C	LLM Qwen2.5-0.5B	0,130	2,373	1,301
P6C	Random Forest (5-CV)	0,440 ± 0,068	1,355	0,208

Tabela 1. Métricas de desempenho dos dois modelos.

4.2. Distribuições agregadas




Figura 1. Distribuição de respostas reais (azul), do LLM (vermelho) e do Random Forest (laranja) para P6A e P6C.

A distribuição real é fortemente assimétrica para o lado da concordância. Em P6A, 38,5% concorda totalmente e 28% concorda em parte; apenas 18,5% discorda totalmente. Em P6C, 45% concorda totalmente, 23,5% em parte; 16% discorda totalmente. Em outras palavras, a maioria dos brasileiros entrevistados concorda com as duas afirmações.

O LLM Qwen-0.5B faz o oposto. Predita 51% em "Discorda totalmente" para P6A e 67% para P6C. Não predita "Concorda totalmente" em nenhuma das duas questões. Zero. Em uma amostra de 600 simulações por questão, isso não é flutuação amostral, é viés sistemático.

O Random Forest segue o caminho que se esperaria de um classificador treinado num dataset desbalanceado: prevê a moda. Coloca 68% em "Concorda totalmente" para P6A e 73% para P6C. Acerta a direção, mas exagera a moda e perde a cauda.

4.3. Acurácia individual




Figura 2. Acurácia individual (*exact match* na escala Likert) de LLM e Random Forest em P6A e P6C.

Vale notar uma referência: um classificador trivial que sempre prevê a moda da população atingiria 38,5% em P6A e 45% em P6C. O Random Forest está próximo desse teto trivial, o que é consistente com a observação de que ele prevê a moda na maior parte do tempo. O LLM está bem abaixo, refletindo o viés de discordância documentado acima.




Figura 3. Matrizes de confusão do LLM para P6A e P6C. As células fora da diagonal estão concentradas nas colunas 3, 4 e 5, mostrando que o LLM responde tendendo à discordância mesmo quando o real é concordância forte.

4.4. Explicabilidade




Figura 4. Importância relativa das variáveis no Random Forest para P6A e P6C.

Religião e faixa etária aparecem como as duas variáveis mais preditivas para ambas as questões. Cada uma responde por algo entre 17% e 20% da importância total. Escolaridade vem em terceiro (15-16%), depois renda familiar (14-15%), região (14%) e cor/raça (11%). Sexo é a menos informativa, com 7-8%.

A baixa importância do sexo pode surpreender em afirmações sobre raça e gênero, mas é coerente com pesquisas que apontam idade, religião e escolaridade como divisores mais fortes da opinião brasileira sobre

desigualdade do que o gênero do respondente. Já a importância alta da religião faz sentido em um contexto onde a divisão evangélico-pentecostal versus católico versus sem-religião marca atitudes sobre temas sociais.

5. Discussão

O resultado central é que um LLM aberto pequeno, sem ajuste fino, falhou em simular a opinião pública brasileira sobre desigualdade. Falhou tanto no individual quanto na distribuição. Três interpretações cabem.

A primeira é capacidade. O Qwen-0.5B tem 500 milhões de parâmetros, contra 13 a 70 bilhões nos modelos usados nos trabalhos de referência. A representação interna do "brasileiro mediano" pode não estar disponível em escala tão pequena. Esse caminho seria testado em trabalhos futuros aumentando o modelo.

A segunda é alinhamento defensivo. Modelos com *instruction tuning* são otimizados, entre outras coisas, para evitar afirmações fortes sobre temas socialmente sensíveis. Diante de uma afirmação como P6A ("a polícia discrimina por cor de pele"), o modelo pode estar escolhendo discordar como estratégia de cautela. Isso explicaria o pico em "Discorda totalmente" e a ausência total de "Concorda totalmente". Seria uma forma de viés de alinhamento, não de viés cultural propriamente dito.

A terceira é distribuição de treino. O Qwen é treinado majoritariamente em inglês e chinês. Mesmo com suporte a português, o conhecimento de *padrões* de opinião brasileira específica sobre desigualdade racial e de gênero pode estar escasso no corpus. Esse caminho seria testado em trabalhos futuros com modelos treinados ou ajustados em corpora em português.

Sobre o Random Forest: ele ganhou nas métricas, mas atinge essa acurácia em parte por uma estratégia trivial: prever a moda da amostra. Para tarefas em que importa simular a *variância* populacional, o Random Forest puro não basta. Seria necessário combiná-lo com calibração de probabilidades, amostragem proporcional a *predict_proba* ou *bootstrap aggregation*. Ou seja: nem LLM pequeno nem Random Forest, sozinhos, simulam bem a heterogeneidade da opinião brasileira.

Limitações. Algumas. O modelo tem só 500M parâmetros. A amostra de 200 limita análises por subgrupo. Usamos sete variáveis sociodemográficas quando o questionário oferece muito mais. O *prompt* foi escolhido após poucas iterações; engenharia mais cuidadosa (*few-shot* com exemplos reais, instrução explícita para evitar cautela) provavelmente reduz o

viés de discordância. E, claro, comparamos com um único *baseline*.

6. Conclusão

Um LLM aberto de 500M parâmetros não conseguiu simular adequadamente a opinião pública brasileira sobre desigualdade. O sintoma mais visível foi um viés de discordância: o modelo concentra metade ou mais das respostas no extremo "Discorda totalmente", enquanto a população real concentra suas respostas no extremo oposto, "Concorda totalmente". O Random Forest treinado nas mesmas variáveis venceu em acurácia individual e em aderência distribucional, mas em boa parte por uma estratégia simples de prever a moda da amostra.

A análise de importância de variáveis identificou religião e faixa etária como os preditores mais informativos, com sexo como o menos. Os caminhos óbvios de continuação são testar modelos maiores (Llama-3-8B, Qwen 7B, Mistral), aplicar *few-shot prompting* com exemplos reais da própria pesquisa, e fazer ajuste fino dirigido a CESOP em português. Todo o pipeline é aberto e reproduzível em CPU em menos de quinze minutos, o que torna esses próximos passos baratos de executar.

Referências

- ARGYLE, L. P. et al. Out of One, Many: Using Language Models to Simulate Human Samples. *Political Analysis*, 31(3):337-351, 2023.
- BISBEE, J. et al. Synthetic Replacements for Human Survey Data? The Perils of Large Language Models. *Political Analysis*, 2024.
- BREIMAN, L. Random Forests. *Machine Learning*, 45(1):5-32, 2001.
- CESOP/IPEC. Pesquisa 04839 — Percepção dos brasileiros sobre temas relacionados à desigualdade. Centro de Estudos de Opinião Pública, Unicamp, jul/2023.
- PARK, J. S. et al. Generative Agents: Interactive Simulacra of Human Behavior. *UIST 2023*.
- QWEN TEAM. *Qwen2.5 Technical Report*. Alibaba Group, 2024.
- Simulating Public Opinion: Comparing Distributional and Individual-Level Predictions from LLMs and Random Forests. *Entropy*, v.27, n.923, 2025.